



# **Implementación de un modelo de deep learning.**

Curso:

Desarrollo de aplicaciones avanzadas de ciencias computacionales (Gpo 301)

Presenta:

Flavio Ruvalcaba Leija

Fecha:

28-05-2024

## **Dataset**

El dataset "Biggest Gender Face Recognition Dataset" de Kaggle es una colección extensa de imágenes faciales utilizadas para la tarea de reconocimiento de género. Este tipo de dataset contiene imágenes etiquetadas con el género de las personas en las fotos, permitiendo entrenar y evaluar modelos de machine learning para predecir el género a partir de una imagen facial.

### **División del Dataset:**

La división del dataset en 70% para entrenamiento (train), 20% para prueba (test) y 10% para validación (validation) es una práctica común en machine learning, y cada parte tiene un propósito específico:

#### **Entrenamiento (70%):**

Propósito: Esta parte se usa para entrenar el modelo, ajustando sus parámetros internos para aprender a identificar patrones y características relevantes para la tarea de reconocimiento de género.

Beneficio: Utilizar una porción significativa del dataset para el entrenamiento permite que el modelo tenga suficiente información para aprender de manera efectiva.

#### **Prueba (20%):**

Propósito: Después de entrenar el modelo, se evalúa su rendimiento en este subconjunto que el modelo no ha visto antes. Esto proporciona una estimación de cómo el modelo se desempeñará con datos nuevos y no vistos.

Beneficio: Ayuda a identificar problemas como el sobreajuste (overfitting) y a medir la precisión y otras métricas de rendimiento del modelo.

#### **Validación (10%):**

**Propósito:** Este subconjunto se utiliza durante el proceso de entrenamiento para ajustar los hiperparámetros del modelo y realizar una selección de modelos. Proporciona una evaluación intermedia del rendimiento del modelo.

**Beneficio:** Permite ajustar el modelo de manera iterativa sin contaminar el conjunto de prueba, asegurando que la evaluación final sea lo más objetiva posible.

- **"A CNN Based Face Gender Classification System"** por Yang et al. (2017): Este paper propone un sistema de clasificación de género facial basado en una red neuronal convolucional (CNN). La arquitectura utilizada en este paper es VGG16, y los resultados obtenidos son prometedores.

He elegido el paper "A CNN Based Face Gender Classification System" por Yang et al. (2017) como base para la implementación de mi modelo de clasificación de género facial por las siguientes razones:

**Relevancia:** El paper se centra específicamente en la tarea de clasificación de género facial, que coincide exactamente con mi objetivo. Esto me asegura que el modelo propuesto ha sido diseñado y evaluado para este tipo de problema en particular.

**Eficacia:** El modelo utiliza la arquitectura VGG16, una red neuronal convolucional (CNN) que ha demostrado ser altamente efectiva para tareas de visión por computadora, incluyendo la clasificación de imágenes. La elección de una arquitectura probada y confiable aumenta las probabilidades de éxito en la implementación.

**Resultados Prometedores:** Los autores del paper reportan resultados de alta precisión en la clasificación de género facial. Esto indica que el modelo tiene un buen potencial para ser aplicado en mi caso de uso y que puedo esperar un rendimiento satisfactorio.

**Simplicidad:** La implementación del modelo parece ser relativamente sencilla, lo que me permitirá realizarla con mayor facilidad utilizando TensorFlow y Keras. Esto es importante considerando mi experiencia y recursos disponibles.

**Disponibilidad de Código:** Los autores del paper proporcionan código fuente para su modelo, lo que me puede servir como referencia valiosa para mi propia implementación. Tener acceso a código existente facilita el proceso de desarrollo y me permite aprender de las mejores prácticas.

En resumen, considero que este paper es una base sólida para la implementación de mi modelo de clasificación de género facial debido a su relevancia, eficacia, resultados prometedores, simplicidad y disponibilidad de código.

## Framework

El framework utilizado para la creación de este modelo es una biblioteca de código abierto desarrollada por Google: TensorFlow y una API de alto nivel para la construcción y entrenamiento de modelos de aprendizaje profundo llamado Keras. Para el modelo utilicé VGG16, una arquitectura de red neuronal convolucional (CNN) muy conocida y ampliamente utilizada en tareas de clasificación de imágenes. Fue desarrollada por el Grupo Visual Geometry Group (VGG) de la Universidad de Oxford. VGG16 es famosa por su simplicidad y su capacidad para extraer características útiles de las imágenes.

## Desempeño:

Epoch	Loss	Accuracy	Val Loss	Val Accuracy
1	0.3220	0.9167	2.3327	0.880
2	0.2016	0.9500	1.1995	0.940
3	0.2756	0.9250	0.7085	0.945
4	0.3119	0.8958	1.2302	0.910
5	0.2719	0.9167	1.0063	0.940

**1. Epoch:** Indica la iteración del proceso de entrenamiento. Cada epoch representa una pasada completa por el conjunto de datos de entrenamiento.

**2. Loss:** La pérdida (Loss) es una medida de qué tan bien el modelo está haciendo sus predicciones durante el entrenamiento. Valores más bajos indican mejores predicciones.

**3. Accuracy:** La precisión (Accuracy) es la proporción de predicciones correctas hechas por el modelo en el conjunto de datos de entrenamiento. Valores más altos indican un mejor rendimiento.

**4. Val Loss:** La pérdida de validación (Val Loss) es similar a la pérdida (Loss) pero calculada en el conjunto de datos de validación. Un valor más alto aquí en comparación con la pérdida de entrenamiento puede indicar sobreajuste.

**5. Val Accuracy:** La precisión de validación (Val Accuracy) es la proporción de predicciones correctas en el conjunto de datos de validación. Valores más altos indican que el modelo generaliza bien a datos nuevos.

## Implicaciones

- **Pérdida y Precisión de Entrenamiento:** Los valores de pérdida y precisión durante el entrenamiento muestran que el modelo está aprendiendo, ya que la pérdida es relativamente baja y la precisión es alta.
- **Pérdida y Precisión de Validación:** La pérdida de validación alta en la primera epoch y más baja en las siguientes sugiere que el modelo inicialmente tenía problemas con el sobreajuste, pero mejoró ligeramente con más entrenamiento. La precisión de validación alta en general indica que el modelo tiene una buena capacidad de generalización, aunque todavía hay espacio para mejorar, especialmente en las primeras epochs donde la pérdida de validación es notablemente alta.

## Ajuste

Para mejorar el rendimiento del modelo y prevenir el sobreajuste, se implementaron las siguientes técnicas de ajuste:

### 1. Regularización:

- Se aplicaron técnicas de regularización, específicamente regularización L2, usando la clase regularizers de Keras. La regularización L2 penaliza los valores grandes de los pesos del modelo, ayudando a prevenir el sobreajuste.

### 2. Ajuste de Hiperparámetros:

- Se modificaron los hiperparámetros del modelo para optimizar su rendimiento. Los cambios realizados fueron:
  - steps\_per\_epoch:** Aumentado de 25 a 50. Esto significa que en cada época, el modelo realiza el doble de pasos, lo que permite ver más datos y potencialmente aprender mejor.
  - validation\_steps:** Aumentado de 10 a 18. Esto significa que se evalúa el modelo en más datos de validación por época, proporcionando una mejor estimación del rendimiento del modelo en datos no vistos.

## Resultados Obtenidos

Después de implementar las técnicas de regularización y ajustar los hiperparámetros, se obtuvieron los siguientes resultados:

Epoch	Loss	Accuracy	Val Loss	Val Accuracy
1	0.7586	0.9260	2.3120	0.8694
2	0.7449	0.9200	1.4196	0.9278
3	0.7271	0.9171	1.2949	0.9389
4	0.6941	0.9260	2.3223	0.9111
5	0.6859	0.9280	1.7478	0.9333
6	0.6844	0.9170	2.1560	0.9278
7	0.6780	0.9210	1.5389	0.9528

**Resultados:**


### 1. Accuracy y Val Accuracy:

- La precisión de entrenamiento es bastante consistente, fluctuando ligeramente entre las épocas.
- La precisión de validación muestra un incremento significativo, especialmente en las últimas épocas, alcanzando un máximo de 0.9528 en la época 7.

### 2. Loss y Val Loss:

- La pérdida de entrenamiento disminuye constantemente, indicando que el modelo está aprendiendo y ajustándose mejor a los datos de entrenamiento.
- La pérdida de validación es más variable, con algunos picos que podrían indicar sobreajuste en ciertas épocas, pero en general, también muestra una tendencia a la disminución.

Estos resultados sugieren que el modelo ha mejorado su rendimiento después de los ajustes, con una precisión de validación final alta y una pérdida de validación relativamente baja.



**Link a la implementación en Google Drive:**

[https://drive.google.com/drive/folders/16i\\_jtLB22ho3U3ZilennOaO6ANkXHKzx](https://drive.google.com/drive/folders/16i_jtLB22ho3U3ZilennOaO6ANkXHKzx)

**Link al dataset de Kaggle:**

<https://www.kaggle.com/datasets/maciejgronczynski/biggest-genderfacerecognition-dataset>

**Link al Paper de investigación:**

<https://iopscience.iop.org/article/10.1088/1742-6596/1490/1/012042>